

MNIST における深層変分情報ボトルネックと分類損失の検討

A Study of Deep Variational Information Bottleneck and Classification Losses on MNIST

AI R&D Center

湘南工科大学 AI R&D Center
Shonan Institute of Technology, AI R&D Center

1 はじめに

深層学習における中間表現は、入力に含まれる情報のうち課題に必要な成分だけを残すことが望ましい。情報ボトルネック (Information Bottleneck, IB) は、目的変数に関する相互情報量を保ちつつ入力に関する相互情報量を抑える圧縮として、この要請を定式化する [1, 2]。深層変分情報ボトルネック (Deep Variational Information Bottleneck, Deep VIB) は、変分推論により IB をニューラルネットワークで最適化する枠組みである [3]。本稿では手書き数字データセット MNIST[6] を用い、全結合ネットワークによる教師あり分類から自己符号化器 (Autoencoder, AE), 変分自己符号化器 (Variational Autoencoder, VAE)[4], Deep VIB へと表現学習を段階的に接続する。さらに、二次元へ制限した潜在空間の配置, 入力空間での敵対的摂動 [7, 8], 交差エントロピー以外の分類損失として Brier スコア [9] およびクラス間類似度に基づく重み付き交差エントロピーを検討する。いずれの設定でも目的関数と変数の定義を明示し、同一の学習条件のもとで識別性能と圧縮の度合いを比較する。

2 準備

2.1 データセットと共通の学習条件

入力は 28×28 のグレースケール画像であり、画素値を $[0, 1]$ へ線形変換する。学習集合は 60,000 枚, 検証集合は 10,000 枚である。最適化手法は Adam[10], 学習率は 0.001, ミニバッチサイズは $N = 128$, エポック数は 10 とする。0 エポック目はパラメータ更新前の初期値評価である。乱数シードは 0 の 1 通りとする。VAE および Deep VIB における圧縮係数は $\beta = 0.001$ で共通とする。 $\beta = 1$ の素朴な証拠下界では事後分布が事前分布へ潰れやすく, 再構成および識別に必要な情報が失われるためである。

2.2 記法

確率変数としての入力画像を $\mathbf{X}$, クラスラベルを Y , 潜在変数を $\mathbf{Z}$ と書く。実現値はそれぞれ $\mathbf{x}$, y , $\mathbf{z}$ である。クラス数は $C = 10$, 平坦化した画素次元は $D = 784$, 潜在次元は J である。ミニバッチ内の標本番号を $n \in \{1, \dots, N\}$ とする。平坦化ベクトルを $\tilde{\mathbf{x}} \in \mathbb{R}^{1 \times D}$ と書く。活性化関数 $f_{\text{ReLU}}(u) = \max(0, u)$ は要素ごとに適用する。シグモイド関数を $\sigma(u) = (1 + \exp(-u))^{-1}$ とする。相互情報量を $I(\cdot; \cdot)$, カルバック・ライブラー情報量 (Kullback-Leibler divergence, KL) を $D_{\text{KL}}(\cdot \| \cdot)$ と書く。

3 手法

3.1 全結合分類器

入力 $\tilde{\mathbf{x}}$ を 3 層の全結合画像でクラスロジット $\ell \in \mathbb{R}^{1 \times C}$ へ変換する。

$$\mathbf{h}_1 = f_{\text{ReLU}}(\tilde{\mathbf{x}} \mathbf{W}_1 + \mathbf{b}_1) \in \mathbb{R}^{1 \times 256} \quad (1)$$

$$\mathbf{h}_2 = f_{\text{ReLU}}(\mathbf{h}_1 \mathbf{W}_2 + \mathbf{b}_2) \in \mathbb{R}^{1 \times 128} \quad (2)$$

$$\ell = \mathbf{h}_2 \mathbf{W}_3 + \mathbf{b}_3 \in \mathbb{R}^{1 \times C} \quad (3)$$

ここで $\mathbf{W}_1 \in \mathbb{R}^{D \times 256}$, $\mathbf{W}_2 \in \mathbb{R}^{256 \times 128}$, $\mathbf{W}_3 \in \mathbb{R}^{128 \times C}$ は重み行列, $\mathbf{b}_1 \in \mathbb{R}^{1 \times 256}$, $\mathbf{b}_2 \in \mathbb{R}^{1 \times 128}$, $\mathbf{b}_3 \in \mathbb{R}^{1 \times C}$ はしきい値ベクトルである。予測クラスは $\hat{y} = \arg \max_k \ell_k$ である。ソフトマックス確率を

$$p_k = \frac{\exp(\ell_k)}{\sum_{k'=1}^C \exp(\ell_{k'})}, \quad k = 1, \dots, C \quad (4)$$

とする。目的関数はカテゴリカル交差エントロピー (Categorical Cross Entropy, CCE) である。

$$\mathcal{L}_{\text{CCE}} = -\frac{1}{N} \sum_{n=1}^N \left(\ell_{n, y_n} - \log \sum_{k=1}^C \exp(\ell_{n, k}) \right) \quad (5)$$

ここで $\ell_{n, k}$ は標本 n のクラス k に対するロジット, y_n は正解クラスである。(5) は $-\log p_{n, y_n}$ の標本平均に等しい。評価指標は正答率

$$\text{Accuracy} = \frac{1}{N} \sum_{n=1}^N \mathbf{1}[\hat{y}_n = y_n] \quad (6)$$

である。 $\mathbf{1}[\cdot]$ は括弧内が真のとき 1, 偽のとき 0 を返す指示関数である。最良モデルは検証正答率の最大で選ぶ。

3.2 自己符号化器

ラベルを用いず, 入力自身を再構成する。符号化器は $\tilde{\mathbf{x}}$ を潜在ベクトル $\mathbf{z} \in \mathbb{R}^{1 \times J}$ ($J = 32$) へ写し, 復号化器は $\mathbf{z}$ から画素 $\hat{\mathbf{x}} \in \mathbb{R}^{1 \times D}$ を返す。

$$\mathbf{h}_1^{(e)} = f_{\text{ReLU}}(\tilde{\mathbf{x}} \mathbf{W}_1^{(e)} + \mathbf{b}_1^{(e)}) \in \mathbb{R}^{1 \times 256} \quad (7)$$

$$\mathbf{h}_2^{(e)} = f_{\text{ReLU}}(\mathbf{h}_1^{(e)} \mathbf{W}_2^{(e)} + \mathbf{b}_2^{(e)}) \in \mathbb{R}^{1 \times 128} \quad (8)$$

$$\mathbf{z} = \mathbf{h}_2^{(e)} \mathbf{W}_3^{(e)} + \mathbf{b}_3^{(e)} \in \mathbb{R}^{1 \times J} \quad (9)$$

$$\mathbf{h}_1^{(d)} = f_{\text{ReLU}}(\mathbf{z} \mathbf{W}_1^{(d)} + \mathbf{b}_1^{(d)}) \in \mathbb{R}^{1 \times 128} \quad (10)$$

$$\mathbf{h}_2^{(d)} = f_{\text{ReLU}}(\mathbf{h}_1^{(d)} \mathbf{W}_2^{(d)} + \mathbf{b}_2^{(d)}) \in \mathbb{R}^{1 \times 256} \quad (11)$$

$$\hat{\mathbf{x}} = \sigma(\mathbf{h}_2^{(d)} \mathbf{W}_3^{(d)} + \mathbf{b}_3^{(d)}) \in \mathbb{R}^{1 \times D} \quad (12)$$

ここで上付き添字 (e) は符号化器, (d) は復号化器を表す. 出力のシグモイドは再構成画素を $[0, 1]$ に収める. 目的関数は平均二乗誤差 (Mean Squared Error, MSE) である.

$$\mathcal{L}_{\text{MSE}} = \frac{1}{ND} \sum_{n=1}^N \sum_{i=1}^D (\hat{x}_{n,i} - x_{n,i})^2 \quad (13)$$

ここで $\hat{x}_{n,i}$ と $x_{n,i}$ は標本 n の第 i 画素である. 評価指標は平均絶対誤差 (Mean Absolute Error, MAE)

$$\text{MAE} = \frac{1}{ND} \sum_{n=1}^N \sum_{i=1}^D |\hat{x}_{n,i} - x_{n,i}| \quad (14)$$

である. 最良モデルは検証 MSE の最小で選ぶ.

3.3 変分自己符号化器

決定的な潜在ベクトルに代え, 近似事後分布 $q(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$ を学習する [4]. 符号化器は平均 $\boldsymbol{\mu} \in \mathbb{R}^{1 \times J}$ と対数分散 $\log \boldsymbol{\sigma}^2 \in \mathbb{R}^{1 \times J}$ を出力する.

$$\boldsymbol{\mu} = \mathbf{h}_2^{(e)} \mathbf{W}_{\boldsymbol{\mu}} + \mathbf{b}_{\boldsymbol{\mu}} \quad (15)$$

$$\log \boldsymbol{\sigma}^2 = \mathbf{h}_2^{(e)} \mathbf{W}_{\log \sigma^2} + \mathbf{b}_{\log \sigma^2} \quad (16)$$

再パラメータ化により

$$\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\epsilon} \odot \exp(0.5 \log \boldsymbol{\sigma}^2), \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (17)$$

を得る. ここで $\odot$ は要素ごとの積, $\mathbf{I}$ は J 次の単位行列, $\mathbf{0}$ は零ベクトルである. 復号化器は (10)–(12) と同型である. 可視化および再構成の評価ではサンプリングを行わず $\boldsymbol{\mu}$ を復号化器へ渡す. 目的関数は β -VAE[5] の加重和である.

$$\mathcal{L}_{\text{VAE}} = \mathcal{L}_{\text{MSE}} + \beta \mathcal{L}_{\text{KL}} \quad (18)$$

KL 項は $q(\mathbf{z}|\mathbf{x})$ と標準正規事前分布 $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ とのダイバージェンスであり, 対角ガウスの閉形式

$$\mathcal{L}_{\text{KL}} = -\frac{1}{2N} \sum_{n=1}^N \sum_{j=1}^J (1 + \log \sigma_{n,j}^2 - \mu_{n,j}^2 - \sigma_{n,j}^2) \quad (19)$$

を用いる. ここで $\mu_{n,j}$ と $\sigma_{n,j}^2$ は標本 n の潜在第 j 成分の平均と分散である. β は圧縮の強さを制御する正の係数であり, 本稿では $\beta = 0.001$ とする. 評価指標は MAE と KL である. 最良モデルは検証損失 $\mathcal{L}_{\text{VAE}}$ の最小で選ぶ.

3.4 深層変分情報ボトルネック

IB は次のトレードオフを最小化することを求める [1].

$$\mathcal{L}_{\text{IB}} = I(\mathbf{Z}; \mathbf{X}) - \beta^{-1} I(\mathbf{Z}; Y) \quad (20)$$

ここで $I(\mathbf{Z}; \mathbf{X})$ は入力に残る情報, $I(\mathbf{Z}; Y)$ はラベルに関する情報である. Deep VIB[3] は, 変分上界と下界によりこれを

$$\mathcal{L}_{\text{VIB}} = \mathcal{L}_{\text{cls}} + \beta \mathcal{L}_{\text{KL}} \quad (21)$$

で近似する. $\mathcal{L}_{\text{KL}}$ は (19) と同一であり $I(\mathbf{Z}; \mathbf{X})$ の変分上界に対応する. 分類項 $\mathcal{L}_{\text{cls}}$ は $I(\mathbf{Z}; Y)$ の変分下界の負に対応し, 本稿では交差エントロピー, Brier スコア, クラス間重み付き交差エントロピーのいずれかを代入する. 符号化器は VAE と同型であり $J = 32$ を標準とする. 復号化器に代え, 線形分類器

$$\boldsymbol{\ell} = \mathbf{z} \mathbf{W}_{\text{out}} + \mathbf{b}_{\text{out}} \in \mathbb{R}^{1 \times C} \quad (22)$$

を置く. ここで $\mathbf{W}_{\text{out}} \in \mathbb{R}^{J \times C}$, $\mathbf{b}_{\text{out}} \in \mathbb{R}^{1 \times C}$ である. 予測時はサンプリングを行わず $\boldsymbol{\mu}$ を (22) へ渡す. 標準設定の分類項は (5) であり,

$$\mathcal{L}_{\text{VIB}}^{\text{CE}} = \mathcal{L}_{\text{CE}} + \beta \mathcal{L}_{\text{KL}} \quad (23)$$

となる. 評価指標は正答率と KL である. 最良モデルは検証正答率の最大で選ぶ.

3.5 二次元潜在空間の可視化

識別に必要な情報が低次元へ残るかを見るため, $J = 2$ として (23) を最適化する. 検証画像ごとの $\boldsymbol{\mu} = (\mu_1, \mu_2)$ を平面上に散布する. 決定領域は点の密度推定ではなく, 潜在平面を格子に切って線形分類器へ通すことで得る. 検証 $\boldsymbol{\mu}$ の最小・最大に余白 0.5 を加え描画範囲 $[x_{\min}, x_{\max}] \times [y_{\min}, y_{\max}]$ を決める. 各軸を $n_{\text{grid}} = 200$ 点で等間隔に区切り, 格子点 $\mathbf{z}_{i,j} \in \mathbb{R}^{1 \times 2}$ を作る. 各格子点に対し

$$\hat{y}_{i,j} = \arg \max_k (\mathbf{z}_{i,j} \mathbf{W}_{\text{out}} + \mathbf{b}_{\text{out}})_k \quad (24)$$

を計算し, 予測クラスを色面として塗る. 分類器は線形であるため, 領域境界は直線に近い.

3.6 Brier スコアを分類項とする定式化

交差エントロピーは正解クラスの $-\log p_y$ のみを見る. これに対し Brier スコア [9] は確率ベクトル全体を one-hot 教師へ近づける.

$$\mathcal{L}_{\text{Brier}} = \frac{1}{NC} \sum_{n=1}^N \sum_{k=1}^C (p_{n,k} - e_{n,k})^2 \quad (25)$$

ここで $p_{n,k}$ は (4) の確率, $e_{n,k}$ は正解が y_n のとき $e_{n,y_n} = 1$, それ以外は 0 の one-hot ベクトルの成分である. VIB 損失は

$$\mathcal{L}_{\text{VIB}}^{\text{Brier}} = \mathcal{L}_{\text{Brier}} + \beta \mathcal{L}_{\text{KL}} \quad (26)$$

である. β および符号化器は交差エントロピーの場合と同一とし, 分類項のみを取り替える. 比較のため $J = 32$ と $J = 2$ の双方で学習する.

3.7 クラス間重み付き交差エントロピー

字形が近い数字同士の混同を強く罰するため, クラス対 (y, k) に非負の重み $W_{y,k}$ を与え, 交差エントロピー

をスケールする． $C = 10$ のもとで有向対は $C^2 = 100$ 通りある．対称性 $W_{yk} = W_{ky}$ を仮定すると，保持すべき独立な値は半分の 50 個である．内訳は，異なるクラスの無順対 (i, j) ($i < j$) が $C(C-1)/2 = 45$ 個，対角のうち先頭 5 成分 $W_{00}, \dots, W_{44}$ が 5 個である．混同項では対角を用いないため $W_{kk} = 0$ とする．長さ 50 のベクトルを対称行列 $\mathbf{W} \in \mathbb{R}^{C \times C}$ へ展開して損失に用いる．似た数字ほど大きい値とし，例えば $W_{3,5} = W_{5,3} = 4.5$ ， $W_{4,9} = 4.5$ ， $W_{1,7} = 3.5$ ，見た目が大きく異なる対は 0.5 とする．重みは学習パラメータではなく，字形の類似に基づく定数である．重み付き交差エントロピーを

$$\mathcal{L}_{\text{WCE}} = -\frac{1}{N} \sum_{n=1}^N \left(1 + \sum_{k \neq y_n} W_{y_n k} p_{n,k} \right) \log p_{n,y_n} \quad (27)$$

と定義する．括弧内は通常の交差エントロピーに対する倍率である．正解 y_n の標本が，類似クラス k へ確率を漏らすほど倍率が 1 より大きくなり $-\log p_{n,y_n}$ が強調される．VIB 損失は

$$\mathcal{L}_{\text{VIB}}^{\text{WCE}} = \mathcal{L}_{\text{WCE}} + \beta \mathcal{L}_{\text{KL}} \quad (28)$$

である．

3.8 入力摂動に対する敵対的学習

全結合分類器に対し，交差エントロピーが大きくなる方向へ入力ノイズ $\delta \in \mathbb{R}^{1 \times D}$ を最適化し，摂動画像 $\mathbf{x} + \delta$ で学習する [8]．固定したモデルのもと，初期値 $\delta = \mathbf{0}$ から射影勾配降下 (Projected Gradient Descent, PGD) を $T = 5$ 回反復する．第 t ステップは

$$\delta \leftarrow \text{clip}_{[-\epsilon, \epsilon]}(\delta + \alpha \text{sign}(\nabla_{\mathbf{x}+\delta} \mathcal{L}_{\text{CE}})) \quad (29)$$

としたのち， $\mathbf{x} + \delta$ が画素範囲 $[0, 1]$ に収まるよう再射影する．ここで $\epsilon = 0.1$ は L_∞ 半径， $\alpha = 0.025$ は 1 ステップの更新幅， $\text{sign}(\cdot)$ は要素ごとの符号， $\text{clip}_{[-\epsilon, \epsilon]}$ は各要素を $[-\epsilon, \epsilon]$ へ制限する写像である．モデル更新に用いる損失は (5) と同一だが，ロジットは $\mathbf{x} + \delta$ に対して計算する．評価はクリーン正答率と，検証時に同じ ϵ ， T ， α で摂動した敵対的正答率の 2 つである．最良モデルは検証の敵対的正答率の最大で選ぶ．

4 実験結果

表 1 に各設定の最良検証指標をまとめる．全結合分類器の検証正答率は 0.9808 である．0 エポック目はチャンスレート近傍であり，学習により 10 エポック以内に約 98% へ到達する．最終エポックでは学習正答率が 0.9941 まで上昇する一方，検証損失が再上昇し過学習の兆候が見られる．自己符号化器は検証 MSE 0.0083，MAE 0.0299 まで再構成誤差を下げた．図 1 に示すとおり，数字の形は識別可能なまま復元されるが，入力より平滑である．32 次元への圧縮と画素平均の二乗誤差最小化により高周波成分が落ちるためである．VAE は同一の β のもとで検証損失 0.0348，MAE 0.0622 を得た．KL は約 11

表 1: 各手法の最良検証指標．VIB 系の β は 0.001 で共通である．

手法	J	分類/再構成項	最良検証値
全結合分類器	—	CCE	Acc 0.9808
自己符号化器	32	MSE	MSE 0.0083
VAE	32	MSE + β KL	MAE 0.0622
Deep VIB	32	CCE + β KL	Acc 0.9785
Deep VIB	2	CCE + β KL	Acc 0.9608
敵対的学習	—	CCE (摂動入力)	AdvAcc 0.8717
Deep VIB	32	Brier + β KL	Acc 0.9696
Deep VIB	2	Brier + β KL	Acc 0.9654
Deep VIB	32	WCE + β KL	Acc 0.9797

へ収束し，事後分布の崩壊は起きなかった．図 2 のとおり再構成は AE より滑らかだが字形は保たれる．KL 正則化が潜在空間を連続化することの表れである．Deep VIB (交差エントロピー) の検証正答率は 0.9785 であり，決定的分類器とほぼ同水準である．KL は学習開始直後に上昇したのち緩やかに減少し，最終エポックでも約 22 を保った．分類項が $I(\mathbf{Z}; Y)$ を押し上げるため， $q(\mathbf{z}|\mathbf{x})$ は識別に必要な情報を残し，VAE で問題となる崩壊を回避できる．図 3 の検証バッチはいずれも正解と一致した． $J = 2$ では検証正答率 0.9608 まで低下する．それでも 96% を超えており，識別情報の大部分は平面に圧縮できる．図 4 では各クラスが原点から放射状のクラスタを形成する．KL 項が $q(\mathbf{z}|\mathbf{x})$ を $\mathcal{N}(\mathbf{0}, \mathbf{I})$ へ引き寄せ，分類項がクラスごとの方向へ μ を押し出すためである．数字 3 と 5 は原点付近で重なる．図 5 の決定領域は外周で扇状，中心で入り組み，散布図の重なりと対応する．敵対的学習では，検証の敵対的正答率 0.8717，同時点のクリーン正答率 0.9746 を得た．クリーン学習の 0.9808 からクリーン性能の低下は小さい．図 6 では摂動は小さく見えるが，数字 9 が 2 へ変わる例が観測された．未学習時の敵対的正答率は 0 であり，交差エントロピーを入力について最大化する方向に分類器は弱い．Brier スコアを分類項とした Deep VIB は， $J = 32$ で検証正答率 0.9696，KL 約 7.6 である．交差エントロピーと比べ正答率は約 0.9 ポイント低く，KL は小さい．同じ β でも勾配が全クラスに分散し，圧縮が強く効く． $J = 2$ では Brier の正答率 0.9654 が交差エントロピーの 0.9608 をわずかに上回る．図 7 では正答率曲線は終盤まで近く，KL は序盤から Brier が低い．図 8 ではどちらも放射状だが，交差エントロピーの μ はおよそ $[-15, 20]$ まで広がり，Brier は $[-6, 6]$ 程度に収まる．クラス間重み付き交差エントロピーでは検証正答率 0.9797 を得た．通常の交差エントロピー (0.9785) と同水準かそれ以上であり，重み付けが学習を壊していない．一方 KL は約 40 と大きい．(27) の倍率が損失の尺度を押し上げるため，同じ β では KL 項の相対的な効きが弱くなる．図 9 に示す対称行列では，3 と 5，4 と 9 など字形の近い対が濃い．

5 むすび

本稿では MNIST を題材に，全結合分類器，自己符号化器，変分自己符号化器，深層変分情報ボトルネックを同一の学習条件で接続し，目的関数と変数を明示して比




図 1: 自己符号化器による再構成. 上段が入力, 下段が再構成である.




図 2: 変分自己符号化器による再構成. 上段が入力, 下段が再構成である.

較した. Deep VIB は交差エントロピーと β KL の和により, 決定的分類器とほぼ同等の正答率を保ちつつ潜在分布を事前分布から離れた識別表現として学習する. 潜在次元を 2 に制限しても正答率は 96% を超え, クラスは放射状に配置される. 分類項を Brier スコアへ替えると, 同じ β で KL が小さく潜在平均は原点付近へ圧縮される. クラス間重み付き交差エントロピーは類似数字の混同を倍率として CCE に乗せる定式化であり, 正答率を維持したまま対ごとの罰則を明示できる. 入力空間の PGD による敵対的学習は, クリーン正答率を大きく落とさずに L_∞ 半径 0.1 の摂動へ耐性を与える. 今後の課題は, β とクラス間重みを検証誤差に応じて適応させること, および潜在空間の配置と敵対的摂動の関係を定量化することである.

参考文献

- [1] N. Tishby, F.C. Pereira, and W. Bialek, “The information bottleneck method,” Proc. Allerton Conf. on Communication, Control, and Computing, 1999.
- [2] N. Tishby and N. Zaslavsky, “Deep learning and the information bottleneck principle,” Proc. IEEE Information Theory Workshop, 2015.
- [3] A.A. Alemi, I. Fischer, J.V. Dillon, and K. Murphy, “Deep variational information bottleneck,” Proc. ICLR, 2017.
- [4] D.P. Kingma and M. Welling, “Auto-encoding variational Bayes,” Proc. ICLR, 2014.
- [5] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, “ β -VAE: Learning basic visual concepts with a constrained variational framework,” Proc. ICLR, 2017.



図 3: Deep VIB (交差エントロピー) による予測例. 上段が入力, 下段が予測クラスである.




図 4: 潜在次元 2 の Deep VIB における検証データの潜在平均 μ の散布図である.

- [6] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” Proc. IEEE, vol.86, no.11, pp.2278–2324, 1998.
- [7] I.J. Goodfellow, J. Shlens, and C. Szegedy, “Explaining and harnessing adversarial examples,” Proc. ICLR, 2015.
- [8] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, and A. Vladu, “Towards deep learning models resistant to adversarial attacks,” Proc. ICLR, 2018.
- [9] G.W. Brier, “Verification of forecasts expressed in terms of probability,” Monthly Weather Review, vol.78, no.1, pp.1–3, 1950.
- [10] D.P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” Proc. ICLR, 2015.




図 5: 200×200 格子を線形分類器へ通して得た決定領域である。




図 6: 敵対的摂動の例。上段が入力，中段がノイズ，下段が $x + \delta$ である。




図 7: 交差エントロピーと Brier スコアの検証正答率 (左) および検証 KL (右) である。




図 8: 潜在次元 2 における交差エントロピー（左）と Brier スコア（右）の μ 分布と決定領域である.




図 9: クラス間重み行列 $\mathbf{W}$. 対称であり, 字形の近い対ほど値が大きい.